Московский государственный технический университет им. Н.Э. Баумана
Факультет «Информатика и системы управления»
Кафедра «Автоматизированные системы обработки информации и управления»

Отчет

Рубежный контроль № 2

По курсу «Технологии машинного обучения»

ИСПОЛНИТЕЛЬ:
Группа ИУ5-65Б
Погосян С.Л.

" " ______ 2021 г.

ПРЕПОДАВАТЕЛЬ:
Гапанюк Ю.Е.

____

"__"___________2021 г.

Москва 2021

РК2

ТМО

Вариант 16, ИУ5-65Б

Погосян С.Л.

Задание.

Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы линейная/логистическая регрессия и градиентный бустинг. Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

- При решении задач можно выбирать любое подмножество признаков из приведенного набора данных.
- Для сокращения времени построения моделей можно использовать фрагмент набора данных (например, первые 200-500 строк).

Датасет: https://www.kaggle.com/san-francisco/sf-restaurant-scores-lives-standard

In [1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

from sklearn.linear_model import LinearRegression
from sklearn.linear_model import LogisticRegression
```

In [2]:
```
data = pd.read_csv("data/restaurant-scores-lives-standard.csv", sep=',')
data.dtypes
```

Out[2]:
```
business_id                       int64
business_name                    object
business_address                 object
business_city                    object
business_state                   object
business_postal_code             object
business_latitude               float64
business_longitude              float64
business_location                object
business_phone_number           float64
inspection_id                    object
inspection_date                  object
inspection_score                float64
inspection_type                  object
violation_id                     object
violation_description            object
risk_category                    object
Neighborhoods (old)             float64
```

```
Police Districts            float64
Supervisor Districts        float64
Fire Prevention Districts   float64
Zip Codes                   float64
Analysis Neighborhoods      float64
dtype: object
```

In [3]:
```
data.isnull().sum()
```

Out[3]:
```
business_id                     0
business_name                   0
business_address                0
business_city                   0
business_state                  0
business_postal_code         1018
business_latitude           19556
business_longitude          19556
business_location           19556
business_phone_number       36938
inspection_id                   0
inspection_date                 0
inspection_score            13610
inspection_type                 0
violation_id                12870
violation_description       12870
risk_category               12870
Neighborhoods (old)         19594
Police Districts            19594
Supervisor Districts        19594
Fire Prevention Districts   19646
Zip Codes                   19576
Analysis Neighborhoods      19594
dtype: int64
```

In [4]:
```
data.shape
```

Out[4]:
```
(53973, 23)
```

In [5]:
```
data.head()
```

Out[5]:

	business_id	business_name	business_address	business_city	business_state	business_postal
0	101192	Cochinita #2	2 Marina Blvd Fort Mason	San Francisco	CA	
1	97975	BREADBELLY	1408 Clement St	San Francisco	CA	
2	92982	Great Gold Restaurant	3161 24th St.	San Francisco	CA	
3	101389	HOMAGE	214 CALIFORNIA ST	San Francisco	CA	
4	85986	Pronto Pizza	798 Eddy St	San Francisco	CA	

5 rows × 23 columns

In [6]:

```
data2 = data.copy().dropna(axis=0, how='any')
data2.drop_duplicates(keep=False,inplace=True)
```

In [7]:

```
for col in data2.columns:
    unique_nums = data2[col].unique()
    if unique_nums.size < 10:
        print("{}: {}".format(col, unique_nums))
```

```
business_city: ['San Francisco']
business_state: ['CA']
inspection_type: ['Routine - Unscheduled']
risk_category: ['Low Risk' 'High Risk' 'Moderate Risk']
```

business_city: ['San Francisco'], business_state: ['CA'], inspection_type: ['Routine - Unscheduled'] - имеют 1 уникальное значение. Можно убрать.

In [8]:

```
fig, ax = plt.subplots(figsize=(15,7))
sns.heatmap(data2.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```

Out[8]:

```
<AxesSubplot:>
```

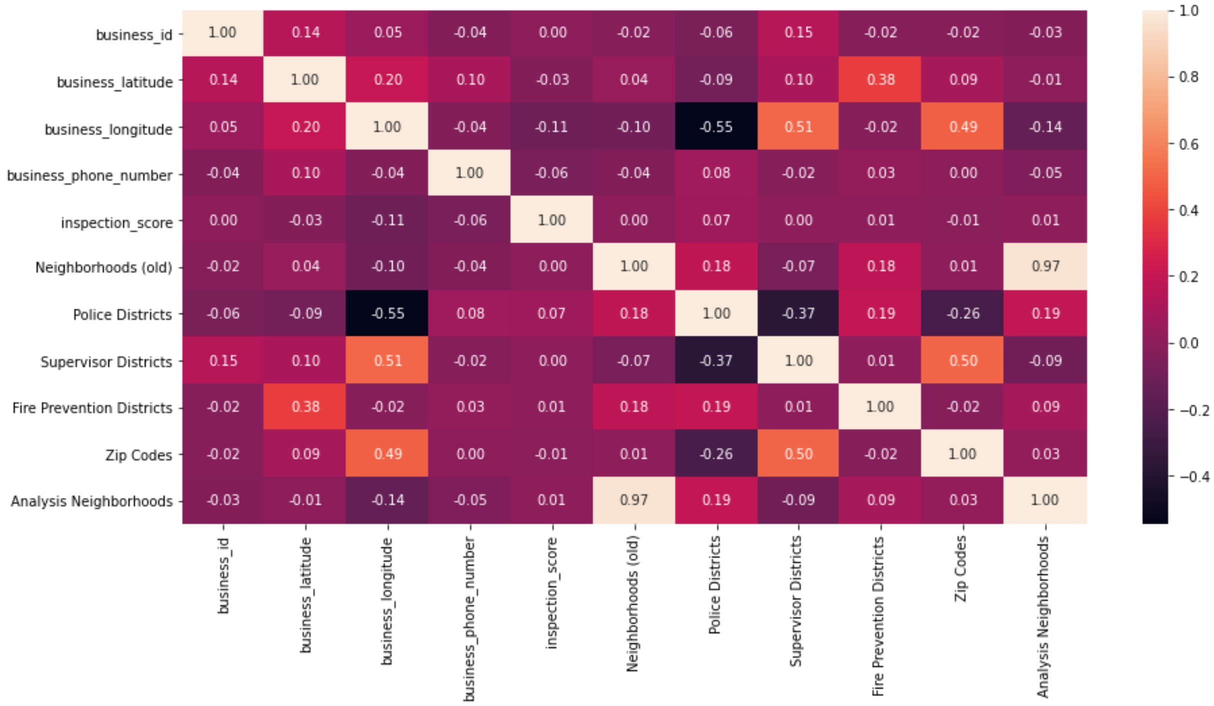

In [9]:

```
data2["risk_category"] = data2["risk_category"].astype('category')
data2["risk_category_cat"] = data2["risk_category"].cat.codes

data2.drop(["business_city", "business_state", "business_location", "business
            "business_address", "violation_description", "risk_category", "Ne
            "inspection_id", "violation_id", "inspection_date"
           ],
           axis=1, inplace=True)
```

In [10]:

```
data2["business_postal_code"].unique()
```

Out[10]:

```
array(['94107', '94131', '94112', '94121', '94110', '94109', '94115',
       '94111', '94118', '94103', '94134', '94117', '94114', '94123',
       '94124', '94104', '94122', '94108', '94133', '94132', '941102019',
       '94127', '94102', '92672', '94105', '94116', '94158'], dtype=object)
```

In [11]:
```
data2["business_postal_code"] = data2["business_postal_code"].astype(int)
```

In [12]:
```
data2["Police Districts"] = data2["Police Districts"].astype(int)
data2["inspection_score"] = data2["inspection_score"].astype(int)
data2["Supervisor Districts"] = data2["Supervisor Districts"].astype(int)
data2["Fire Prevention Districts"] = data2["Fire Prevention Districts"].astyp
data2["Zip Codes"] = data2["Zip Codes"].astype(int)
data2["Analysis Neighborhoods"] = data2["Analysis Neighborhoods"].astype(int)
```

In [13]:
```
data2.isnull().sum()
```

Out[13]:
```
business_id                  0
business_postal_code         0
business_latitude            0
business_longitude           0
business_phone_number        0
inspection_score             0
Police Districts             0
Supervisor Districts         0
Fire Prevention Districts    0
Zip Codes                    0
Analysis Neighborhoods       0
risk_category_cat            0
dtype: int64
```

In [14]:
```
data2.head()
```

Out[14]:

	business_id	business_postal_code	business_latitude	business_longitude	business_phone_n
11	4794	94107	37.778634	-122.393089	1.41556
372	2684	94131	37.746759	-122.426995	1.41552
464	3256	94112	37.709737	-122.450070	1.41553
484	3951	94121	37.779962	-122.485087	1.41553
496	4864	94110	37.759174	-122.419066	1.41558

In [15]:
```
data2.dtypes
```

Out[15]:
```
business_id                    int64
business_postal_code           int64
business_latitude            float64
business_longitude           float64
business_phone_number        float64
inspection_score               int64
Police Districts               int64
Supervisor Districts           int64
Fire Prevention Districts      int64
Zip Codes                      int64
Analysis Neighborhoods         int64
risk_category_cat               int8
dtype: object
```

In [16]:
```
target = "Supervisor Districts"
```

In [17]:
```python
# Масштабирование
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
for col in data2.columns:
  if col != target:
    data2[col] = scaler.fit_transform(data2[[col]])
```

In [18]:
```python
fig, ax = plt.subplots(figsize=(15,7))
sns.heatmap(data2.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```

Out[18]:
```
<AxesSubplot:>
```

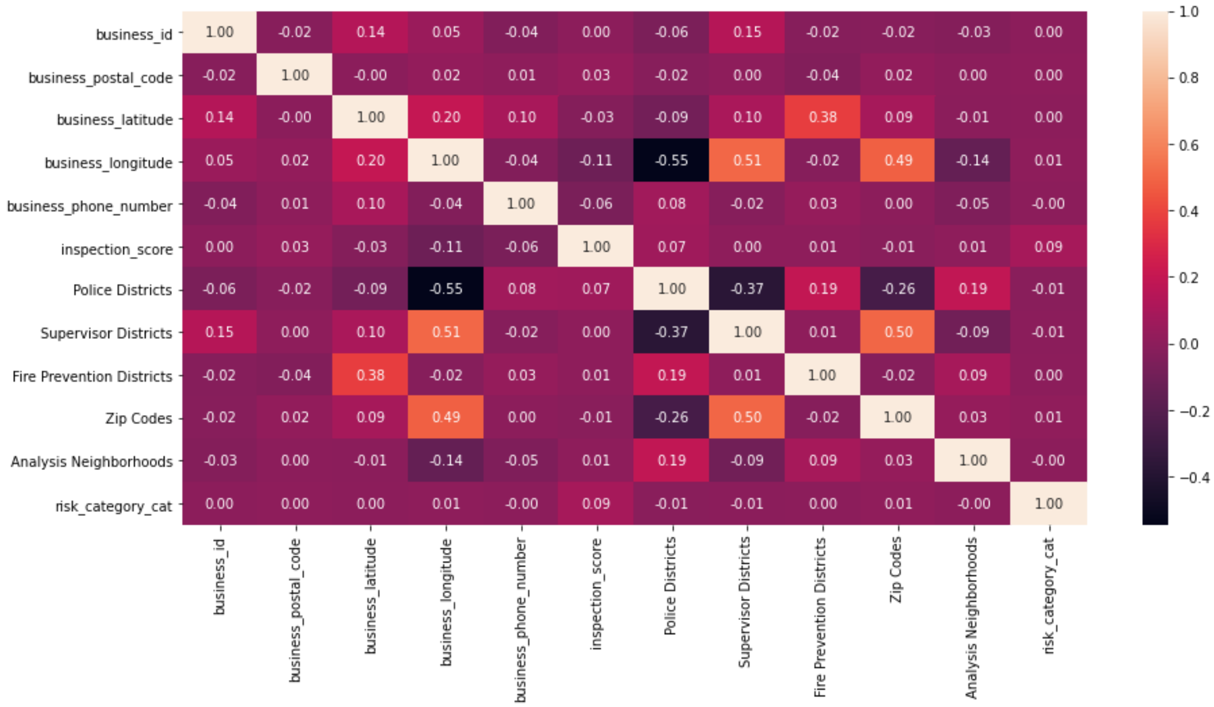

In [19]:
```python
from sklearn.model_selection import train_test_split

feature_cols = ["business_latitude", "business_longitude", "Zip Codes"]

X_train, X_test, y_train, y_test = train_test_split(
  data2[feature_cols],
  data2[target],
  test_size=0.3,
  random_state=1,
)
```

Линейная регреессия

In [20]:
```python
from sklearn.linear_model import LinearRegression

linreg = LinearRegression().fit(X_train, y_train)
```

In [21]:
```python
from sklearn.metrics import r2_score, mean_absolute_error

linreg_predict = linreg.predict(X_test)
r2_score(y_test, linreg_predict), \
  mean_absolute_error(y_test, linreg_predict)
```

Out[21]: (0.32634156097620515, 1.8639363772620643)

Градиентный бустинг

In [22]:
```
from sklearn.ensemble import GradientBoostingRegressor

gboostreg = GradientBoostingRegressor(random_state=10).fit(X_train, y_train)
```

In [23]:
```
gboostreg_predict = gboostreg.predict(X_test)
r2_score(y_test, gboostreg_predict), \
  mean_absolute_error(y_test, gboostreg_predict)
```

Out[23]: (0.9155392208894986, 0.4158270828303186)

Вывод

Как видно по тепловой карте, данные плохо коррелируют друг с другом. Поэтому для построения модели был выбрал целевой признак "Supervisor Districts", а в качестве ключевых признаков - ["business_latitude", "business_longitude", "Zip Codes"]. Как видно по оценкам, модель линейной регрессии недообучается, а модель градиентного бустинга хорошо обучается. Вторая модель имеет высокую оценку r2(близкую к 1) и низкую абсолютную ошибку(<1, что для целочисленного признака дает хороший результат).

In [ ]:
```
```